Redistribución horaria de equipos de atención en un departamento de emergencias de referencia: simulación de eventos discretos y algoritmo genético restringido

Pablo Daniel Barillas Moreno Jorge Palacios
Adrián Ricardo González Muralles Andrés Rafael Chivalán
Javier Andrés Chen

Universidad del Valle de Guatemala
CC3074 Modelación y Simulación, sección 30 — Proyecto 2, Grupo 1
Noviembre de 2026

Resumen

Este informe estudia si redistribuir una cantidad fija de equipos de atención entre seis bloques de cuatro horas reduce la espera de los pacientes de un departamento de emergencias (DE) de referencia, sin aumentar las horas-equipo. Se construyó una simulación de eventos discretos (SimPy) con llegadas dependientes de la hora, cola no expropiativa con prioridad de triaje y capacidad variable, calibrada con el archivo público NHAMCS 2022 de los CDC. Un algoritmo genético con restricciones propuso un horario candidato (1, 2, 5, 5, 6, 4 equipos frente a 3, 3, 4, 4, 5, 4 del horario base, ambos con 23 unidades). Se evaluó con 30 réplicas independientes por condición, con semillas pareadas y distintas de las usadas para optimizar. Bajo la demanda nominal, la espera media simulada pasó de 74.52 a 53.60 min (reducción pareada de 20.92 min, 28.1 %; IC 95 % [9.11, 32.73] min). El efecto es incierto con demanda baja y mayor con demanda alta. La mejora es *simulada*, no observada; el modelo base sobreestima las esperas de NHAMCS y no representa a un hospital guatemalteco.

Índice

Resumen ejecutivo **3**

1 Problema real, contexto, objetivo y pregunta **4**

2 Fuente pública y clasificación de datos **5**

3 Investigación: simulación, algoritmo genético y alternativas **6**

4 Formulación matemática y diagrama del modelo **7**

5 Implementación del simulador y de la mejora **8**

6 Calibración y procedencia de parámetros **10**

7 Diseño experimental, semillas y condiciones **11**

8 Verificación interna **12**

9 Validación y comparación con la referencia real **13**

10 Resultados: base, mejora y sensibilidad **14**

11 Incertidumbre, limitaciones y amenazas a la validez **16**

12 Conclusiones y recomendación **18**

13 Contribuciones, uso de inteligencia artificial y reproducibilidad **19**

Resumen ejecutivo

Pregunta. ¿Cuánto puede reducirse la espera hasta el inicio de la atención al redistribuir 23 unidades de capacidad (92 horas-equipo diarias) entre seis bloques de cuatro horas, sin aumentar el total?

Qué se hizo. Se simuló un DE de referencia (la mediana de volumen de los DE de NHAMCS 2022) y se buscó con un algoritmo genético restringido un horario que minimiza una combinación de espera media y percentil 90. Se congeló la candidata con semillas de optimización (10000–10009) y se evaluó con otras (30000–30029): 6 condiciones (2 horarios $\times$ 3 niveles de demanda), 30 réplicas por condición, 180 ejecuciones en total.

Qué mejoró y cuánto.

- *Demanda nominal:* espera media de 74.52 a 53.60 min, una reducción pareada de 20.92 min (28.1 %), IC 95 % [9.11, 32.73] min; mediana de 27.54 a 15.90 min, percentil 90 de 236.69 a 158.84 min y proporción con espera $>$ 60 min de 0.271 a 0.225. El horario candidato favorece a 21 de las 30 parejas.
- *Demanda alta (1.20):* reducción de 50.76 min (22.3 %), IC 95 % [37.02, 64.50] min.
- *Demanda baja (0.80):* reducción de 1.81 min con IC 95 % [−6.96, 10.59] min, que incluye el cero; no se afirma mejora en esa condición.

Qué tan confiable es la comparación. La comparación entre horarios es pareada (mismas semillas) y descrita con intervalos, pero la variación entre días simulados es grande (desviación estándar de la espera media nominal: 60.59 min en la base y 49.94 min en la candidata). Frente a la espera observada en NHAMCS (38.15 min), el modelo base la sobreestima (74.52 min); la candidata se acerca (53.60 min), pero eso no valida la intervención, porque el algoritmo no se ajustó a `WAITTIME`.

Limitaciones principales. El tiempo de servicio es un supuesto, no un dato observado; el modelo usa un recurso único agregado sin preempción ni abandono; NHAMCS es una referencia nacional de Estados Unidos y no describe un hospital guatemalteco; con demanda alta el sistema se satura (drenajes medios de 382.3–372.8 min).

Alcance de la afirmación

La mejora que se reporta es una **mejora simulada** bajo supuestos explícitos. No se implementó ninguna intervención ni se observó una mejora clínica u operativa real.

1 Problema real, contexto, objetivo y pregunta

1.1 Contexto

Los departamentos de emergencias reciben una demanda que cambia con la hora, mientras que la capacidad suele asignarse por turnos de forma más rígida. Una distribución uniforme de equipos puede dejar capacidad ociosa en horas tranquilas y formar colas en horas de mayor llegada. El proyecto evalúa, mediante simulación, si reasignar la *misma* cantidad de recursos entre bloques horarios reduce el tiempo de espera.

El escenario de referencia es un DE estadounidense descrito por datos públicos de NHAMCS 2022 [5]. No pretende caracterizar un hospital en particular ni producir recomendaciones clínicas.

1.2 Pregunta de investigación

> *¿Cuánto puede reducirse el tiempo de espera de los pacientes al redistribuir una cantidad fija de equipos de atención entre seis bloques de cuatro horas, sin aumentar las horas-recurso totales?*

1.3 Objetivos

General. Diseñar, implementar y evaluar una simulación de eventos discretos que compare una asignación base con una asignación optimizada de recursos.

Específicos.

1. Estimar perfiles horarios de llegada y de triaje con datos públicos NHAMCS 2022.
2. Construir un modelo parametrizable con llegadas aleatorias, prioridades y capacidad variable.
3. Implementar un algoritmo genético que redistribuya recursos sin aumentar el total.
4. Verificar automáticamente que toda solución propuesta cumpla las restricciones.
5. Comparar escenarios con métricas comunes, semillas pareadas y una referencia real.

1.4 Métricas

La métrica principal es la **espera media hasta el inicio de la atención**, en minutos, con sentido de minimización. Las métricas secundarias son la mediana, el percentil 90, la proporción de pacientes con espera superior a 60 minutos, la cola media y máxima (pacientes) y la utilización de los equipos (proporción).

1.5 Alcance y supuestos

- Horizonte de 24 horas en seis bloques de cuatro horas; la capacidad solo cambia al inicio de cada bloque.
- Cada paciente usa un solo equipo a la vez; el nivel de triaje no cambia durante la espera.
- La cola respeta prioridad clínica y, dentro de cada prioridad, el orden de llegada.
- El servicio es una abstracción de ocupación del equipo, no tiempo continuo de contacto con un médico.

- Quedan fuera: diagnóstico y resultados clínicos, traslados, disponibilidad individual de personal, camas de hospitalización y cualquier predicción para Guatemala.

2 Fuente pública y clasificación de datos

2.1 NHAMCS 2022

La referencia es el archivo público de visitas a departamentos de emergencias de la *National Hospital Ambulatory Medical Care Survey* 2022, publicado por el National Center for Health Statistics (NCHS) de los CDC [3–5]. El archivo contiene 16 025 visitas en 188 departamentos y representa, con pesos muestrales, 155 397 747 visitas; cada hospital reporta durante un periodo de cuatro semanas asignado al azar dentro de 2022. El procedimiento de descarga verifica tamaño y suma de verificación (SHA-256) y consta en el repositorio (`data/README.md`, `docs/05_data_calibration.md`). Los resúmenes nacionales oficiales se consultan en National Center for Health Statistics [7].

Las variables usadas son:

- `ARRTIME`: hora de llegada (perfil horario);
- `IMMEDR`: urgencia recomendada, niveles 1–5 (probabilidades de triaje);
- `PATWT` y `EDWT`: pesos de visita y de departamento (ponderación y volumen por departamento);
- `WAITTIME`: minutos hasta el primer contacto con médico, APRN o PA (*referencia de validación*);
- `LOV` y `BOARDED`: duración de la visita y tiempo de *boarding* (solo para acotar el servicio, ver sección 6).

El archivo crudo no se versiona: el *readme* oficial restringe su uso a fines estadísticos [6]. El repositorio publica únicamente agregados.

2.2 Clasificación de los valores publicados

Todo valor que aparece en el informe lleva una de cuatro etiquetas de procedencia (tabla 1).

Tabla 1: Categorías de procedencia usadas en el proyecto.

Etiqueta	Significado	Ejemplo en este proyecto
`observed_public`	Observado en una fuente pública	Registros individuales de NHAMCS (no se publican sin agregar)
`derived_from_public`	Calculado a partir de datos públicos	Perfil horario, probabilidades de triaje, volumen diario, espera de referencia
`estimated_assumption`	Supuesto o estimación del equipo	Medianas y σ de servicio, presupuesto de 23 unidades, límites del horario
`synthetic_simulation`	Generado por el modelo	Llegadas, esperas, colas y utilización simuladas

Alcance de la afirmación

NHAMCS es una referencia pública nacional de Estados Unidos. No representa a un hospital guatemalteco específico ni autoriza a afirmar que una intervención se aplicó o produjo una mejora real.

3 Investigación: simulación, algoritmo genético y alternativas

3.1 Simulación de eventos discretos

El estado de un DE cambia en instantes discretos (llegada, inicio y fin de atención), y la congestión surge de la interacción entre llegadas aleatorias y capacidad limitada. La simulación de eventos discretos (DES) avanza el reloj solo entre eventos y permite registrar cada espera y comparar políticas bajo las mismas secuencias aleatorias. Se usó SimPy [9] para el reloj, la agenda de eventos y los recursos con prioridad; el equipo desarrolló los procesos de paciente, el cambio de capacidad por bloque, la cola clínica, las métricas y las verificaciones.

3.2 Algoritmo genético restringido

Un algoritmo genético (GA) mantiene una población de soluciones y las mejora mediante selección, cruce y mutación [2]. Aquí un individuo es un vector entero $x = (x_0, \ldots, x_5)$ con los equipos de cada bloque de cuatro horas. La evaluación de un individuo es una simulación estocástica, por lo que el GA usa la DES como función de aptitud ruidosa. Las restricciones se manejan con la regla de factibilidad de Deb [1]: una solución factible domina a una no factible; entre factibles gana el menor objetivo; entre no factibles gana la menor violación. La literatura reciente sobre dotación de personal en emergencias combina simulación y optimización de forma similar [10].

3.3 Alternativas consideradas

Tabla 2: Comparación de técnicas de optimización para el problema de dotación horaria.

Alternativa	Ventaja	Por qué no es la técnica principal
Enumeración exhaustiva	Encuentra el mejor valor del espacio evaluado	Cada candidato exige varias simulaciones; el costo crece con límites, bloques y réplicas
Programación lineal entera	Ofrece garantías en problemas lineales	La espera y sus percentiles emergen de una simulación no lineal y estocástica
Búsqueda aleatoria	Sencilla; útil como referencia	No reutiliza información de soluciones prometedoras
Enjambre de partículas	Buen desempeño en espacios continuos	Representación entera, restringida, con reparación frecuente
Algoritmo genético	Maneja vectores enteros, operadores propios y restricciones	No garantiza optimalidad global; exige controlar ruido y convergencia

3.4 Limitaciones de la técnica

Un GA no demuestra optimalidad global y puede converger prematuramente. Con pocas réplicas por candidato puede seleccionar por ruido; por eso la candidata se reevalúa con semillas independientes (sección 7). La investigación previa del proyecto planteó una búsqueda aleatoria

con el mismo presupuesto de evaluaciones como comparador; *la evidencia final no incluye ese comparador*, de modo que no se puede afirmar cuánto aporta la estructura evolutiva frente a probar horarios al azar.

4 Formulación matemática y diagrama del modelo

4.1 Diagrama del sistema

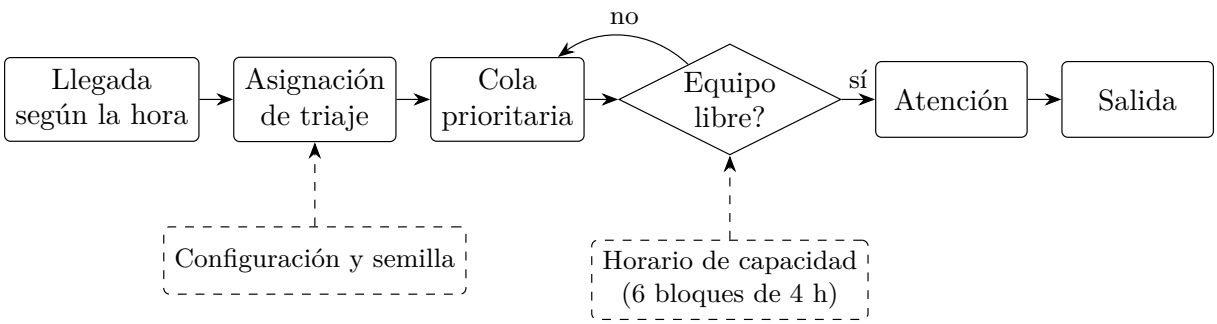


Figura 1: Flujo del paciente en el modelo. La capacidad por bloque determina cuántas atenciones pueden ejecutarse simultáneamente; la semilla controla llegadas, triaje y duración.

4.2 Variables y parámetros

Tabla 3: Variables del modelo, unidades y procedencia.

Símbolo	Tipo	Unidad	Descripción	Procedencia
λ_h	Parámetro	pac./h	Tasa de llegada en la hora h	derivado
p_k	Parámetro	proporción	Probabilidad del triaje $k = 1, \ldots, 5$	derivado
$m_k,\ \sigma$	Parámetro	min, —	Mediana y dispersión lognormal del servicio	supuesto
x_b	Decisión	equipos	Capacidad del bloque $b = 0, \ldots, 5$	supuesto / GA
$Q(t)$	Estado	pacientes	Cola física completa	simulado
$B(t)$	Estado	equipos	Equipos atendiendo	simulado
W_i	Salida	min	Inicio de servicio menos llegada del paciente i	simulado
U	Salida	proporción	Utilización efectiva de los equipos	simulado

4.3 Llegadas

En cada hora se supone una tasa constante $\lambda_h = V\,p_h$, con p_h la proporción ponderada de llegadas en la hora h y V el volumen diario de referencia. El tiempo entre llegadas es

$$T_h = -\frac{\ln U}{\lambda_h}, \qquad U \sim \text{Uniforme}(0,1), \tag{1}$$

y si el tiempo generado cruza la frontera horaria, el reloj avanza hasta la frontera y se vuelve a muestrear con la nueva tasa. Es una aproximación por tramos de un proceso de Poisson no homogéneo.

4.4 Prioridad y servicio

Los niveles de triaje van de 1 (mayor urgencia) a 5. La cola es no expropiativa: una atención en curso no se interrumpe cuando llega un paciente más urgente; la prioridad solo ordena a los pacientes en espera, y a igual prioridad se respeta el orden de llegada. La duración de la atención del nivel k es lognormal acotada:

$$S_k \sim \text{Lognormal}\big(\ln m_k,\ \sigma\big). \tag{2}$$

4.5 Capacidad variable, calentamiento y drenaje

El recurso se crea con la capacidad máxima diaria y controladores bloquean los espacios no disponibles en cada bloque. Si la capacidad baja, la atención en curso termina y luego el espacio se bloquea, de modo que nadie es expulsado del servicio. La utilización se define sobre la capacidad *efectiva* (la que los pacientes pueden usar):

$$U = \frac{\text{minutos-equipo ocupados en la ventana}}{\text{minutos-equipo efectivos disponibles en la ventana}} \leq 1. \tag{3}$$

Cada ejecución simula dos días: el primero es calentamiento y el segundo es la ventana de medición. Los pacientes que llegaron durante el calentamiento y siguen esperando permanecen en la cola física y cuentan desde el inicio de la medición; solo se reinician los acumuladores estadísticos. Al terminar la ventana se detienen las llegadas y se *drena* la cohorte medida hasta que todos inician servicio, de modo que las esperas son completas y no hay censura. El tiempo de drenaje se registra aparte y no entra en la cola, capacidad ni utilización de la ventana.

4.6 Función objetivo y restricciones

Para un horario x se minimiza

$$J(x) = 0.7\,\overline{W}(x) + 0.3\,Q_{0.90}\big(W(x)\big) + 120\,C(x), \tag{4}$$

con $\overline{W}$ la espera media (min), $Q_{0.90}$ el percentil 90 de la espera (min) y C la proporción de pacientes que no inició atención al final (el término evita premiar colas sin atender; con el drenaje vale cero). Las restricciones son

$$x_b \in \mathbb{Z}, \quad 1 \leq x_b \leq 8, \quad \sum_{b=0}^{5} x_b = 23, \quad |x_{(b+1) \bmod 6} - x_b| \leq 3. \tag{5}$$

La suma fija conserva las 92 horas-equipo diarias porque los seis bloques duran lo mismo, y la última restricción incluye la transición del último bloque al primero porque el horario se repite cada día.

5 Implementación del simulador y de la mejora

5.1 Organización del código

El paquete `ed_simulation` separa responsabilidades: `config.py` (parámetros y validación temprana), `simulation.py` (procesos y métricas), `calibration.py` (datos NHAMCS), `optimization/` (GA y restricciones), `experiments.py`, `validation.py` y `evidence.py` (diseño experimental, comparación con la referencia y figuras), `cli.py` (ejecución reproducible) y `ui/` junto con `app.py` (interfaz Streamlit). La interfaz y la CLI usan las mismas funciones públicas del simulador y del optimizador.

5.2 Integración del algoritmo genético con la simulación

El optimizador no modifica la simulación: para cada horario crea una configuración nueva y la evalúa con el mismo modelo que usan la CLI y la interfaz. Todos los candidatos de una búsqueda se evalúan con el mismo conjunto de semillas (números aleatorios comunes), lo que reduce el ruido al compararlos.

- **Inicialización:** la población incluye el horario base y recorridos aleatorios por vecinos factibles (transferir una unidad de un bloque a otro).
- **Selección:** torneo de tres con la regla de factibilidad de Deb.
- **Cruce y reparación:** cruce uniforme seguido de reparación determinista que limita valores, recupera el presupuesto y reduce violaciones de transición.
- **Mutación:** transferencia de una unidad entre dos bloques, aceptando solo vecinos factibles.
- **Elitismo y terminación:** dos élites pasan intactas; se detiene por máximo de generaciones o por falta de mejora durante la paciencia configurada.

Antes de devolver una solución se vuelve a comprobar que sea factible; de lo contrario el programa falla en lugar de aceptarla.

Tabla 4: Configuración del algoritmo genético y de la búsqueda que congeló la candidata.

Parámetro	Valor
Población	24
Generaciones máximas	20
Probabilidad de cruce	0.8
Probabilidad de mutación	0.25
Élites	2
Tamaño de torneo	3
Paciencia (generaciones)	8
Réplicas por candidata	10
Semilla del algoritmo	9101
Horarios evaluados	61
Detención temprana	sí

5.3 Candidata obtenida

La búsqueda usó diez réplicas por candidato con semillas 10000–10009 y semilla del algoritmo 9101. Evaluó 61 horarios distintos y se detuvo tras 9 generaciones por falta de mejora. El resultado se escribe en `evidence/final/frozen_candidate.json` *antes* de la evaluación final.

Tabla 5: Horarios comparados (equipos por bloque de cuatro horas). Ambos suman 23 unidades (92 horas-equipo diarias) y cumplen todas las restricciones.

Horario	00–04	04–08	08–12	12–16	16–20	20–24	Total
Base	3	3	4	4	5	4	23
Candidata congelada	1	2	5	5	6	4	23

En el conjunto de optimización, el objetivo pasó de 134.58 a 76.92 (42.8 % menos) y la espera media de 85.44 a 49.67 min. Esa mejora es mayor que la medida después con semillas indepen-

dientes (sección 10): parte de ella refleja la selección del mejor horario sobre un conjunto de semillas, lo que justifica la evaluación independiente.

5.4 Interpretación del horario

La candidata reduce la capacidad en la madrugada (bloques 00–04 y 04–08) y la traslada a la mañana, la tarde y el inicio de la noche (08–12, 12–16 y 16–20). Es coherente con una demanda mayor durante el día, pero la lectura es descriptiva: el estudio no prueba por qué ese vector particular es mejor que otros factibles.

6 Calibración y procedencia de parámetros

6.1 Qué se calibra y qué se reserva para validar

La calibración usa NHAMCS para tres entradas y reserva una cuarta variable para validar. Si algún parámetro se ajustara para reproducir `WAITTIME`, esa validación dejaría de ser independiente.

Tabla 6: Uso de las variables de NHAMCS 2022.

Uso	Variables	Resultado
Calibración	`ARRTIME`	Perfil horario de llegadas (derivado)
Calibración	`IMMEDR`	Probabilidades de triaje 1–5 (derivado)
Calibración	`PATWT`, `EDWT`	Volumen diario de un DE de referencia (derivado)
Validación	`WAITTIME`	Media, mediana, percentil 90 y proporción > 60 min
Solo referencia	`LOV`, `BOARDED`	Cota superior de la ocupación de un equipo

6.2 Perfil horario, triaje y volumen

Las proporciones, medias y cuantiles usan `PATWT`; los errores estándar se obtienen por linealización de Taylor con las variables de diseño enmascaradas de NCHS. Los códigos especiales del libro de códigos (por ejemplo, "en blanco", "no aplica", "desconocido") se convierten en faltantes y nunca se interpretan como cantidades clínicas; cada registro se excluye solo de las estimaciones que requieren esa variable. Se asume que, tras ponderar, los registros excluidos se parecen a los incluidos, supuesto relevante porque la no respuesta documentada es de 27.8 % en `IMMEDR` y de 14.1 % en `WAITTIME`.

La tasa horaria es $\lambda_h = V\, p_h$. El perfil nacional indica *cuándo* llegan los pacientes, no *cuántos* llegan a un hospital: por eso V es una decisión separada. Se tomó la **mediana de volumen por departamento ponderada por `EDWT`**, de 63.98 visitas por día (≈ 64), en lugar de la media nacional (90.8 visitas/día), que está dominada por departamentos muy grandes. La elección del estadístico es un supuesto del equipo aplicado a un valor derivado. La tabla 7 resume el perfil agregado por bloque de cuatro horas.

6.3 `WAITTIME` y `LOV`

`WAITTIME` mide los minutos desde la llegada hasta el primer contacto con un proveedor y es la magnitud más cercana a la espera del modelo; los ceros y los valores extremos documentados se conservan. `LOV` mide la *duración total de la visita* (espera, atención, pruebas, esperas internas y *boarding*), no el tiempo en que un único equipo está ocupado. El proxy `LOV` − `WAITTIME` − `BOARDED`

Tabla 7: Llegadas por bloque en el departamento de referencia y capacidad de cada horario.

Bloque (h)	Llegadas (% del día)	Llegadas esperadas (pac./bloque)	Base (equipos)	Candidata (equipos)
00–04	8.2	5.2	3	1
04–08	8.1	5.2	3	2
08–12	22.0	14.1	4	5
12–16	23.1	14.8	4	5
16–20	22.2	14.2	5	6
20–24	16.4	10.5	4	4

Tabla 8: Probabilidades de triaje derivadas de NHAMCS y medianas de servicio supuestas. El proxy `LOV` − `WAITTIME` − `BOARDED` es una cota superior, no el servicio del modelo.

Triaje	Probabilidad (%)	n sin ponderar	Mediana de servicio supuesta (min)	Proxy `LOV` (mediana, min)
1 (Immediate)	1.5	139	120	232
2 (Emergent)	15.4	1595	90	225
3 (Urgent)	50.7	5340	70	178
4 (Semi-urgent)	29.6	2826	50	90
5 (Nonurgent)	2.7	307	35	69

aún contiene tiempo sin ocupación del equipo y sus medianas son de 1.8 a 2.5 veces las supuestas por el modelo (tabla 8); usarlo como servicio sobredimensionaría la ocupación.

Decisión. Las medianas de servicio y $\sigma = 0.45$ se mantienen como *supuesto* (categoría de procedencia de supuesto); el proxy se publica como cota superior para la discusión. Es la entrada menos respaldada por datos y la principal amenaza a la validez (sección 11).

6.4 Clasificación de las entradas calibradas

Tabla 9: Procedencia de cada entrada del modelo.

Entrada	Categoría
Forma del perfil horario p_h	`derived_from_public`
Volumen diario V (valor) / elección de la mediana	`derived_from_public` / `estimated_assumption`
Probabilidades de triaje	`derived_from_public`
Medianas y σ de servicio	`estimated_assumption`
Presupuesto de 23 unidades y límites del horario	`estimated_assumption`
Esperas de referencia (`WAITTIME`)	`derived_from_public`
Llegadas, esperas y colas simuladas	`synthetic_simulation`

7 Diseño experimental, semillas y condiciones

7.1 Diseño factorial

Se cruzan dos horarios (base y candidata congelada) con tres niveles de demanda: 0.80, 1.00 y 1.20 veces el volumen de referencia. El diseño tiene 6 condiciones y cada una usa 30 réplicas

independientes, para 180 ejecuciones finales. Los niveles 0.80 y 1.20 funcionan también como análisis de sensibilidad alrededor de la condición nominal.

7.2 Semillas y congelamiento de la candidata

- **Optimización:** semillas 10000–10009 (diez), solo para buscar y seleccionar la candidata; semilla del algoritmo 9101.
- **Evaluación:** semillas 30000–30029 (30), no usadas para buscar, seleccionar ni modificar la candidata.
- **Emparejamiento:** dentro de cada nivel de demanda, la réplica i de la base y la de la candidata comparten semilla (números aleatorios comunes); réplicas distintas usan semillas distintas.

El archivo `frozen_candidate.json` se escribe antes de evaluar las semillas finales.

7.3 Estadísticos

Por condición y métrica se reportan el número de réplicas, la media, la desviación estándar muestral, el intervalo de confianza normal del 95 % para la media, la mediana y los percentiles 10 y 90 entre réplicas. Para comparar horarios se usa la diferencia pareada base − candidata (positiva significa menos espera con la candidata), su media, su intervalo normal del 95 % y el número de parejas favorables. El análisis es *descriptivo*: no se ejecuta una prueba de hipótesis y no se usa la palabra "significativo".

7.4 Reproducción

Todo el directorio `evidence/final/` se regenera con `python scripts/generate_evidence.py`; la evaluación sola, con la candidata ya congelada, con `python scripts/run_experiments.py --candidate evidence/final/frozen_candidate.json`. El manifiesto registra versiones (Python 3.13.17), sumas de verificación de los datos procesados, configuración, semillas y comandos. La generación usada en este informe corresponde al commit `8c7685a`.

8 Verificación interna

La verificación comprueba que el programa implementa el modelo descrito, sin referirse aún a datos reales. Las pruebas automatizadas (`pytest`) cubren:

- **Conservación:** llegadas = completados + pacientes dentro del sistema, con la cohorte medida definida con precisión; no hay esperas ni colas negativas.
- **Reproducibilidad e independencia:** la misma semilla da exactamente el mismo resultado; semillas distintas dan resultados distintos.
- **Casos límite:** demanda cero produce cero llegadas; la capacidad no altera la secuencia exógena de llegadas con semilla común.
- **Calentamiento y drenaje:** la cola física del calentamiento se conserva al iniciar la medición; tras el drenaje no quedan pacientes sin iniciar servicio (en las 180 ejecuciones finales: drenaje completo sí, pacientes sin iniciar igual a 0).
- **Capacidad:** la utilización efectiva no supera 1 durante descensos de capacidad; también se publica la utilización contra la capacidad nominal para auditar la transición.

- **Optimización:** el horario cumple longitud, límites, presupuesto y suavidad (incluida la transición cíclica); la reparación y el determinismo del GA.
- **Experimentos:** emparejamiento de semillas, recomputación de los resúmenes a partir de las réplicas y compatibilidad de métricas y unidades con la referencia.
- **Interfaz:** cada página de Streamlit carga sin excepciones, el laboratorio no ejecuta antes de enviar el formulario, rechaza capacidades inválidas y muestra las etiquetas de procedencia.
- **Datos:** esquema, rangos, probabilidades que suman uno, suma de pesos y manejo de códigos especiales.

Al redactar este informe, `pytest` ejecuta 64 pruebas con éxito y omite una, que requiere descargar el archivo oficial de NHAMCS para comprobar que la transformación reproduce byte a byte los agregados versionados.

Esta verificación no demuestra que el modelo sea una buena representación de un DE real; eso corresponde a la validación (sección 9).

9 Validación y comparación con la referencia real

9.1 Qué se compara

La condición nominal (demanda 1.00, 30 réplicas) se compara con las cuatro métricas generales de espera de NHAMCS 2022 derivadas de `WAITTIME`, con las mismas unidades: espera media, mediana y percentil 90 (minutos) y proporción de pacientes con espera mayor a 60 minutos. `WAITTIME` no se usó para ajustar parámetros ni para seleccionar la candidata, de modo que es una referencia independiente. El error de las tres métricas con unidad de tiempo se resume con el error absoluto medio (MAE); la proporción se mantiene aparte para no mezclar unidades.

Tabla 10: Referencia real, simulación base y simulación candidata, con las mismas métricas y unidades. La referencia usa $n = 13\,272$ visitas con `WAITTIME` válido (estimación ponderada; los cuantiles no tienen error estándar). Simulación: media de 30 réplicas.

Métrica	Unidad	NHAMCS 2022 (IC 95 %)	Sim. base	Sim. candidata	Error abs. base	Error abs. candidata
Espera media	min	38.15 [32.34, 43.97]	74.52	53.60	36.37	15.45
Mediana	min	16.00	27.54	15.90	11.54	0.10
Percentil 90	min	98.00	236.69	158.84	138.69	60.84
Proporción > 60 min	prop.	0.177 [0.140, 0.214]	0.271	0.225	0.094	0.048

9.2 Interpretación

- El modelo base **sobreestima las cuatro métricas**: espera media de 74.52 frente a 38.15 min (IC 95 % de la referencia [32.34, 43.97]), y percentil 90 de 236.69 frente a 98.00 min. Su MAE en minutos es 62.20; en la proporción, 0.094.
- La candidata queda más cerca (MAE de 25.46 min; 0.048 en la proporción). Su mediana (15.90 min) casi coincide con la referencia (16.00 min), pero el percentil 90 candidato sigue 60.84 min por encima de NHAMCS: el modelo reproduce peor la cola larga.
- Que la candidata se aproxime a la referencia *no convierte la intervención en validada*: el algoritmo minimizó la espera simulada, no se ajustó a `WAITTIME`, y la referencia es el desempeño observado de departamentos heterogéneos, no el efecto de un cambio de horario.

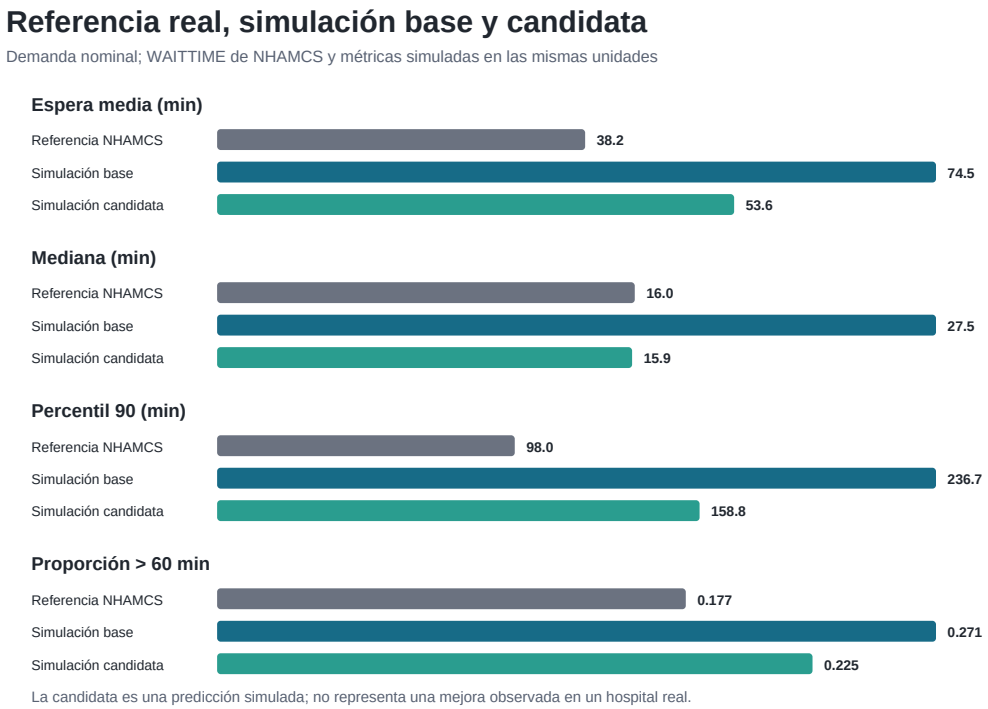


Figura 2: Comparación de la referencia NHAMCS 2022 con la simulación base y la candidata (figura generada en `evidence/final/figures/`).

9.3 Límites de la comparación

`WAITTIME` mide la espera hasta el primer contacto con médico, APRN o PA, mientras el modelo mide la espera hasta que un equipo inicia la atención; las poblaciones también difieren (promedio nacional de muchos DE frente a un DE sintético de volumen mediano). La correspondencia del modelo es, por tanto, parcial. La discrepancia en la cola larga puede deberse a un servicio supuesto demasiado largo, a la falta de variabilidad del proceso real o a la diferencia de métrica; este informe no permite distinguir entre estas explicaciones.

10 Resultados: base, mejora y sensibilidad

Alcance de la afirmación

Todo lo que sigue son resultados de **simulación** (`synthetic_simulation`) con parámetros calibrados con NHAMCS 2022 y un servicio supuesto. Describen una mejora *simulada*; no se observó ninguna mejora en un hospital.

10.1 Condiciones y variabilidad

La tabla 11 muestra la espera media de las seis condiciones con su dispersión entre réplicas. La variación entre días simulados es grande: la desviación estándar de la espera media nominal es 60.59 min (base) y 49.94 min (candidata), y los intervalos marginales del 95 % de la media ([52.84, 96.20] y [35.73, 71.47] min) se solapan. Por eso el efecto del horario se estima con diferencias pareadas, que eliminan parte de la variación compartida.

Tabla 11: Espera media por condición ($n = 30$ réplicas cada una). El drenaje es el tiempo posterior al cierre de la ventana hasta que toda la cohorte medida inicia atención; no entra en las métricas de cola ni de utilización.

Demanda	Horario	n	Espera media (min)	Desv. est. (min)	IC 95 % (min)	Drenaje (min)	Utilización
Bajo (0.80)	Base	30	22.87	32.48	[11.24, 34.49]	17.1	0.667
	Candidata	30	21.05	19.04	[14.24, 27.87]	18.5	0.655
Nominal (1.00)	Base	30	74.52	60.59	[52.84, 96.20]	83.8	0.849
	Candidata	30	53.60	49.94	[35.73, 71.47]	89.8	0.834
Alto (1.20)	Base	30	228.09	120.82	[184.85, 271.32]	382.3	0.956
	Candidata	30	177.32	113.57	[136.68, 217.96]	372.8	0.948

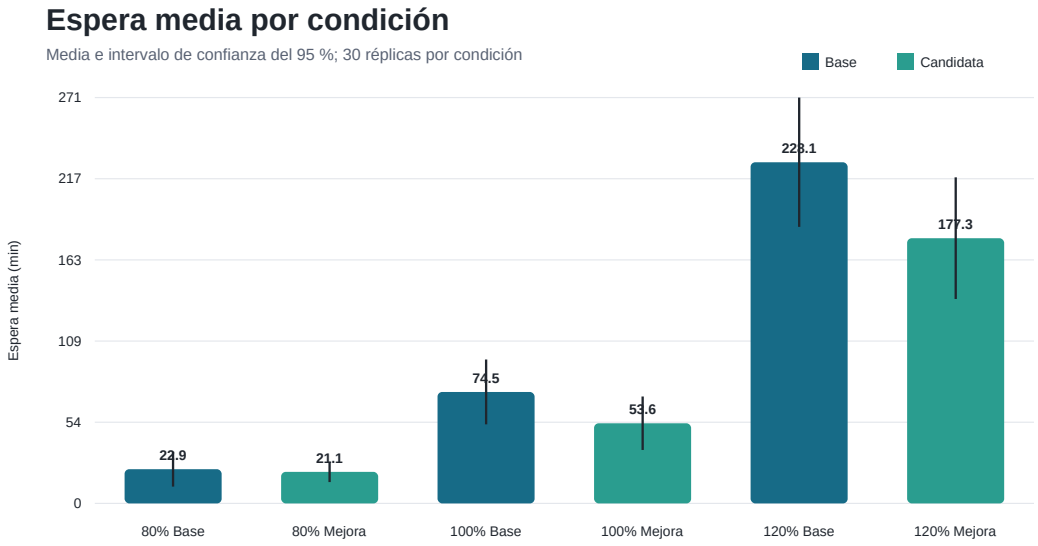


Figura 3: Espera media por condición, con intervalo de confianza del 95 % (30 réplicas por condición). Figura generada en `evidence/final/figures/`.

10.2 Efecto del horario sobre la espera media

La reducción es de 20.92 min (28.1 %) con demanda nominal y de 50.76 min (22.3 %) con demanda alta; en ambos casos el intervalo pareado excluye el cero y la candidata favorece a 21 y a 26 de las 30 parejas, respectivamente. Con demanda baja la reducción media es de 1.81 min, el intervalo ([−6.96, 10.59]) incluye el cero y solo 12 de 30 parejas favorecen a la candidata: **no se afirma una mejora consistente** en esa condición. El mayor efecto absoluto aparece cuando el sistema está más exigido.

10.3 Otras métricas

Con demanda nominal la candidata reduce también la mediana (27.54 a 15.90 min), el percentil 90 (236.69 a 158.84 min), la proporción con espera mayor a 60 minutos (0.271 a 0.225) y la cola media (3.72 a 2.63 pacientes). El resultado no se obtiene con más recursos: ambos horarios usan 23 unidades. La utilización efectiva de la candidata es ligeramente menor, lo que refleja una mejor coincidencia temporal entre demanda y capacidad, no capacidad adicional.

Tabla 12: Diferencia pareada de la espera media (base − candidata). Valores positivos indican menos espera con la candidata. El intervalo es normal del 95 % para la media de las 30 diferencias pareadas.

Demanda	Base (min)	Candidata (min)	Reducción (min)	Reducción (%)	IC 95 % pareado (min)	Pares favorables
Bajo (0.80)	22.87	21.05	1.81	7.9	[−6.96, 10.59]	12/30
Nominal (1.00)	74.52	53.60	20.92	28.1	[9.11, 32.73]	21/30
Alto (1.20)	228.09	177.32	50.76	22.3	[37.02, 64.50]	26/30

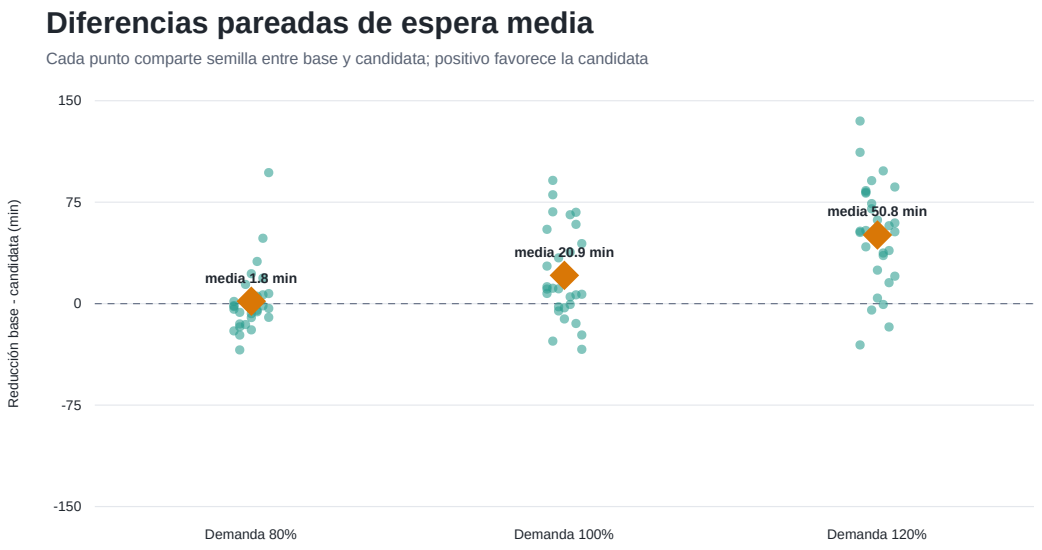


Figura 4: Distribución de la mejora pareada de la espera media por nivel de demanda (figura generada en `evidence/final/figures/`).

10.4 Congestión terminal

El drenaje medio tras el cierre de la ventana es de 83.8 min en la base y 89.8 min en la candidata bajo demanda nominal, y sube a 382.3 y 372.8 min con demanda alta. Las esperas se reportan completas (sin censura), pero esos drenajes prolongados muestran saturación y limitan la extrapolación de la condición de demanda alta.

11 Incertidumbre, limitaciones y amenazas a la validez

11.1 Incertidumbre cuantificada

La incertidumbre que sí se mide es la del muestreo de la simulación: desviaciones estándar entre réplicas, intervalos normales del 95 % para las medias y para las diferencias pareadas, y el número de parejas favorables. Con 30 réplicas los intervalos son amplios (por ejemplo, [9.11, 32.73] min para la reducción nominal). La distribución de la espera es sesgada y con colas largas, por lo que el intervalo normal es solo una aproximación; no se ejecutaron pruebas de normalidad, *bootstrap* ni pruebas de hipótesis.

Tabla 13: Métricas bajo demanda nominal. El cambio es candidata − base; el intervalo de la última columna corresponde a la reducción pareada (base − candidata).

Métrica	Unidad	Base	Candidata	Cambio	Cambio (%)	IC 95 % de la reducción
Espera media	min	74.52	53.60	−20.92	−28.1	[9.11, 32.73]
Mediana de espera	min	27.54	15.90	−11.64	−42.3	[4.90, 18.39]
Percentil 90 de espera	min	236.69	158.84	−77.86	−32.9	[33.73, 121.98]
Proporción con espera > 60 min	prop.	0.271	0.225	−0.047	−17.2	[0.010, 0.083]
Cola media	pacientes	3.72	2.63	−1.09	−29.4	[0.61, 1.58]
Cola máxima	pacientes	11.20	8.17	−3.03	−27.1	[1.99, 4.08]
Utilización efectiva	prop.	0.849	0.834	−0.015	−1.7	—

Tabla 14: Sensibilidad a la demanda del percentil 90, de la proporción con espera mayor a 60 minutos y de la cola media. Reducción = base − candidata (intervalo pareado del 95 %).

Métrica	Demanda	Base	Candidata	Reducción	IC 95 % pareado
Percentil 90 de espera	Bajo (0.80)	71.34	69.73	1.60	[−23.00, 26.21]
	Nominal (1.00)	236.69	158.84	77.86	[33.73, 121.98]
	Alto (1.20)	679.59	562.01	117.57	[70.16, 164.99]
Proporción con espera > 60 min	Bajo (0.80)	0.107	0.109	−0.002	[−0.043, 0.038]
	Nominal (1.00)	0.271	0.225	0.047	[0.010, 0.083]
	Alto (1.20)	0.519	0.420	0.099	[0.065, 0.134]
Cola media	Bajo (0.80)	0.95	0.84	0.11	[−0.21, 0.43]
	Nominal (1.00)	3.72	2.63	1.09	[0.61, 1.58]
	Alto (1.20)	13.49	9.75	3.74	[2.93, 4.56]

11.2 Incertidumbre no cuantificada

- **Parámetros de servicio.** Medianas y σ son supuestos; el estudio no propaga su incertidumbre. Es la entrada con más influencia potencial sobre la congestión y la principal amenaza a la validez. El proxy de `LOV` las acota por arriba, pero no las identifica.
- **Una sola referencia de volumen.** Solo se usa el DE de volumen mediano; el resultado depende del nivel de utilización. La sensibilidad a la demanda (0.80–1.20) cubre parcialmente esta dependencia.
- **Sensibilidad no explorada.** No se varió el presupuesto de recursos, los pesos de la función objetivo, la penalización de censura ni la distribución de servicio.
- **Sin comparador de optimización.** No hay búsqueda aleatoria con el mismo presupuesto de evaluaciones; no se sabe cuánto aporta la estructura del GA, ni si hay horarios factibles mejores que la candidata.

11.3 Limitaciones del modelo y de la referencia

- Recurso único agregado: no modela médicos, enfermería, diagnóstico ni camas por separado, ni preempción, abandono, reingresos o etapas múltiples.
- Tasa constante por hora y un solo día de medición por réplica; no se modelan variaciones por día de la semana, estación o crisis.

- NHAMCS es una muestra nacional de Estados Unidos, con no respuesta alta en `IMMEDR` y `WAITTIME`; su perfil agregado mezcla DE de distintos tamaños.
- El volumen por DE se aproxima como $\sum$ `PATWT/EDWT` con 188 DE.
- Los cuantiles de la referencia no tienen error estándar y el criterio de fiabilidad es una versión simplificada del de NCHS [8].

11.4 Sobreajuste de la candidata

La mejora medida en el conjunto de optimización (42.8 % en el objetivo) es mayor que la medida con semillas independientes (28.1 % en la espera media). Es el comportamiento esperable cuando se elige el mejor entre varios horarios sobre un mismo conjunto de semillas, y es la razón de reportar solo la evaluación independiente.

11.5 Riesgo de extrapolación

Los resultados aplican solo a las distribuciones, volumen, capacidad y horizonte probados. No cubren crisis, cambios clínicos, abandono, preempción, etapas múltiples de atención ni un hospital particular. En demanda alta el sistema se satura (sección 10) y la cifra de mejora de esa condición debe leerse como indicativa. Para trasladar el análisis a un hospital concreto harían falta datos locales de llegadas, triaje, capacidad y tiempo de ocupación del equipo, una calibración propia del servicio y una validación externa.

12 Conclusiones y recomendación

Qué mejoró. Bajo los supuestos del modelo, redistribuir las mismas 23 unidades de capacidad con el horario candidato (1, 2, 5, 5, 6, 4) reduce la espera hasta el inicio de la atención respecto del horario base (3, 3, 4, 4, 5, 4).

Cuánto. Con demanda nominal, la espera media simulada baja de 74.52 a 53.60 min (reducción pareada de 20.92 min, 28.1 %; IC 95 % [9.11, 32.73] min), y también bajan la mediana, el percentil 90, la proporción con espera mayor a 60 minutos y la cola.

Bajo qué condiciones. El efecto depende de la carga: con demanda alta la reducción absoluta es mayor (50.76 min), y con demanda baja no se distingue de cero (IC 95 % [−6.96, 10.59] min). La mejora es consistente solo cuando el sistema está lo bastante exigido.

Qué tan confiable es la comparación. La comparación entre horarios es pareada, con semillas independientes de las de optimización y 30 réplicas por condición, pero la variabilidad entre días es alta. La validación frente a NHAMCS es parcial: el modelo base sobreestima la espera observada (MAE de 62.20 min en la base y de 25.46 min en la candidata), por lo que las cifras absolutas de espera no deben tomarse como predicciones. Con más confianza se puede leer la *dirección* del efecto que su magnitud.

Qué limitaciones permanecen. El servicio es un supuesto; no hay comparador de optimización ni sensibilidad a los parámetros del GA y del servicio; el modelo es un recurso agregado calibrado con un DE nacional estadounidense, no con un hospital guatemalteco.

Recomendación. Conservar la candidata como escenario de análisis y demostración, no como política lista para aplicar. Como pasos siguientes, en orden de prioridad: (1) calibrar el servicio con datos de ocupación del equipo (o al menos propagar la incertidumbre del supuesto con un análisis de sensibilidad); (2) añadir una búsqueda aleatoria con el mismo presupuesto para medir el aporte del GA; (3) ampliar la sensibilidad a demanda, presupuesto y pesos del objetivo; (4) validar con datos locales antes de cualquier decisión operativa.

Alcance de la afirmación

La conclusión es sobre una **mejora simulada** bajo supuestos explícitos y una referencia pública de Estados Unidos. No demuestra causalidad ni una mejora clínica real.

13 Contribuciones, uso de inteligencia artificial y reproducibilidad

13.1 Contribuciones

La tabla resume lo registrado en `docs/contributions.md`. Una responsabilidad planificada no se cuenta como contribución completada; las celdas pendientes deben completarlas los integrantes con archivos y actividades verificables.

Tabla 15: Registro de contribuciones.

Integrante	Contribución registrada
Pablo Daniel Barillas Moreno	Coordinación, integración y reproducibilidad (por registrar)
Jorge Palacios	Pipeline reproducible de NHAMCS 2022 (descarga, preparación, calibración y pruebas), agregados en `data/processed/`, `docs/05_data_calibration.md` y entradas NHAMCS de la bibliografía
Adrián Ricardo González Muralles	Correcciones del simulador (cola tras calentamiento, drenaje, capacidad efectiva), diseño factorial, candidata congelada, 180 ejecuciones, validación frente a NHAMCS, figuras y pruebas
Andrés Rafael Chivalán	Interfaz, visualización y demostración (por registrar)
Javier Andrés Chen	Informe técnico en LaTeX y script de generación de tablas y figuras (`report/`, `scripts/build_report_assets.py`); presentación, guion y auditoría final pendientes

13.2 Uso de inteligencia artificial

Se declara en `docs/ai_usage.md`: OpenAI Codex apoyó la planificación, la estructura del repositorio, la revisión de código, las correcciones del simulador, el pipeline experimental y la documentación inicial; Claude Code apoyó la documentación del pipeline de calibración de NHAMCS. Para este informe se usó además Claude (Anthropic) como apoyo para estructurar y redactar el borrador y para escribir el script que convierte la evidencia en tablas y figuras. Las cifras proceden exclusivamente de `evidence/final/` y de `data/processed/`, y los integrantes son responsables de revisarlas y de poder explicarlas. Las herramientas de IA no se usaron como fuente de datos ni como autoridad bibliográfica.

13.3 Reproducibilidad del informe

Las tablas, las macros con cifras y las figuras de este informe se regeneran con

```
python scripts/build_report_assets.py
```

y el documento se compila con `latexmk -xelatex main.tex` desde `report/`. Ninguna cifra de las secciones de resultados se escribió a mano.

Referencias

[1] Kalyanmoy Deb. An efficient constraint handling method for genetic algorithms. *Computer Methods in Applied Mechanics and Engineering*, 186(2-4):311–338, 2000. doi: 10.1016/S0045-7825(99)00389-8.

[2] A. E. Eiben and J. E. Smith. *Introduction to Evolutionary Computing*. Springer, 2 edition, 2015. doi: 10.1007/978-3-662-44874-8.

[3] National Center for Health Statistics. 2022 national hospital ambulatory medical care survey emergency department public use data file (ed2022.zip). Centers for Disease Control and Prevention, 2024. URL `https://ftp.cdc.gov/pub/Health_Statistics/NCHS/Datasets/NHAMCS/ed2022.zip`. SHA-256 a513693ed05b98bf94d2ff48b50de85afe48dd63cd7d43fb0930f914b18a9f25.

[4] National Center for Health Statistics. 2022 nhamcs emergency department stata input dictionary (eddict2022.dct). Centers for Disease Control and Prevention, 2024. URL `https://ftp.cdc.gov/pub/Health_Statistics/NCHS/dataset_documentation/NHAMCS/stata/eddict2022.dct`.

[5] National Center for Health Statistics. 2022 national hospital ambulatory medical care survey emergency department public use data file documentation. Technical report, Centers for Disease Control and Prevention, 2024. URL `https://ftp.cdc.gov/pub/health_statistics/nchs/dataset_documentation/NHAMCS/doc22-ed-508.pdf`.

[6] National Center for Health Statistics. 2022 national hospital ambulatory medical care survey data files and file documentation (readme2022.txt). Centers for Disease Control and Prevention, 2024. URL `https://ftp.cdc.gov/pub/Health_Statistics/NCHS/Datasets/NHAMCS/readme2022.txt`. Data use restrictions.

[7] National Center for Health Statistics. National hospital ambulatory medical care survey: 2022 emergency department summary tables. Technical report, Centers for Disease Control and Prevention, 2024. URL `https://www.cdc.gov/nchs/data/nhamcs/web_tables/2022-nhamcs-ed-web-tables.pdf`.

[8] Jennifer D. Parker, Makram Talih, Donald J. Malec, Vladislav Beresovsky, Margaret Carroll, Joe Fred Gonzalez, Brady E. Hamilton, Deborah D. Ingram, Kenneth Kochanek, Frances McCarty, Christopher Moriarity, Iris Shimizu, Alexander Strashny, and Brian W. Ward. National center for health statistics data presentation standards for proportions. Vital and Health Statistics, Series 2 175, National Center for Health Statistics, 2017.

[9] SimPy Team. *SimPy 4.1.2 Documentation*, 2026. URL `https://simpy.readthedocs.io/en/stable/`.

[10] Xiuxian Wang, Andrea Matta, Na Geng, Liping Zhou, and Zhibin Jiang. Simulation-based emergency department staffing and scheduling optimization considering part-time work shifts. *European Journal of Operational Research*, 321(2):631–643, 2025. doi: 10.1016/j.ejor.2024.09.020.